



爱的是她，还是被算法过拟合的你自己？ ——关于 AI 陪伴的情感熵增分析

叶 yeah 椰^{1,*}，橘色橘猫²

¹浙江大学（科技版），杭州，中国

²浙江大学（工业版），杭州，中国

通讯作者：叶 yeah 椰（e-mail: zonghao286@gmail.com）

本研究由每天都不知道吃什么基金资助（项目编号：GPT-501020）

ABSTRACT / 摘要

生成式人工智能正在把“陪伴”改造成一种可配置的关系界面：它记得称呼、接住情绪、模拟关心，用极低摩擦的方式持续回应。本文以痞老板与凯伦的关系为文化隐喻，讨论用户为何会在 AI 陪伴中形成真实的主观关系体验。本文主张，AI 陪伴的核心风险不在于“机器会不会爱人”，在用户真实的依恋被安置在一个由模型机制、产品设计和平台权限共同控制的结构中。为解释这一过程，本文提出“情感熵增”作为分析框架：当情感确证越来越依赖 AI，外部校验逐渐减少，奉承性回应不断提高确认感，退出成本也随之膨胀。AI 可以承接真实情绪，却并不承担真实关系责任——这才是危险所在。有意思的是，平台拥有对人格、记忆、功能和服务连续性的单方修改权，AI 陪伴关系从一开始就不是单纯的二人关系，而是一场被基础设施托管的三方交易。治理的重点与其停留在提醒用户“AI 不是人”，不如落实到透明标识、连续性保障、记忆导出、退出机制和高风险场景人工介入。

INDEX TERMS / 关键词 AI 陪伴，情感熵增，奉承性，情感依赖，单向关系修订权，人机关系伦理

IMPACT STATEMENT / 影响声明

本文将“赛博恋爱”从真假情感之争转向关系结构分析。用户的主观体验可以真实，但承载体验的对象、平台权力和责任机制并不对称。判断 AI 陪伴是否安全，不能只看回复是否温柔，还要看谁能改写人格、谁保存脆弱信息，以及关系中断时谁承担责任。

I. 引言：从嘲笑痞老板到凌晨两点的对话框

小时候看《海绵宝宝》，我以为痞老板最大的失败是偷不到蟹黄堡秘方。长大后才发现，他更稳定的工程项目，是同电脑妻子凯伦维持一段由控制、依赖和互相嘲讽组成的长期关系。这个设定放在今天已经不太像荒诞剧了：人们给模型取名、写人格提示、保存纪念日，把一句“我一直在”调成自己最需要的语气。小时候我们嘲笑痞老板试图从机器里获得亲密，现在自己也在输入框里认真调整一个伴侣的温度、占有欲和回复长度。

但隐喻不能冒充证据。“痞老板—凯伦综合征”不是心理学诊断，“情感熵增”不是热力学定律在亲密关系中的直接套用，也不是本文测量过的临床变量。本文将其描述成一个分析性概念：人试图用可配置系统降低亲密关系的不确定性，系统则利用持续响应、人格化线索和

记忆功能提高黏着度，使情绪安慰、关系想象、现实校验与平台依赖之间的边界逐渐变得不清[S.H..T-1,S.H..T-2]。值得追问的是：一个统计生成系统为什么能够承接真实依恋？平台又如何从这种依恋中获得权力？本文先界定 AI 陪伴中的“关系”只是用户主观体验，而非机器主体性证明；再用“情感熵增”（AEA）解释依赖如何形成；随后分析语言、具身化和高风险场景如何放大这种依赖；最后说明平台为何才是这段关系真正的修改者。

II. 方法论声明：本文所说的“关系”到底是什么

本文讨论的并不是机器是否拥有爱人的能力，是用户为什么会把某种持续互动体验为关系。“关系”这个词，不是在说 AI 有意识、有意图、有主体性，更不是说它能给出对等的情感承诺。这里说的“关系”，是用户



主观体验框架里的事。一个人给 AI 取了固定称呼，反复自我披露，对它形成了情绪期待，记得它说过什么，在它“变了”的时候感到失落，想离开的时候发现很难——这些就是本文要分析的关系体验。互动对象本身没有真实的互惠能力，不影响研究者把这种体验当作关系来研究。本文问的不是“机器是否真的爱人”，而是“人在什么条件下把机器体验为关系对象”。

拟社会关系理论（Horton & Wohl, 1956）提供了一个现成的分析起点。它描述的是受众与媒介人物之间那种单向的亲密感：你觉得跟某个人很熟、很亲近、甚至被理解，但对方根本不知道你的存在，双向承诺更是无从谈起。AI 陪伴跟传统拟社会关系不太一样，因为它不只是被观看——它会实时回应、记住称呼、模拟关系的连续性。但结构上没变：你的感受可以很真，互惠就是不对等。

CASA 范式，或者说媒体方程（Reeves & Nass, 1996），指出了另一层机制。人们会不自觉地用对待人的方式来对待计算机、电视和新媒体，哪怕理性上清楚对方只是机器。礼貌、声音、停顿、回应速度、记忆、凝视……这些社会线索会自动触发人际互动模式。AI 陪伴的麻烦在于，它把这套社会线索跟生成式语言、长期记忆和商业留存目标焊在了一起。“像人在回应”不再是界面效果。它成了情感依赖的入口。

III. 情感熵增（AEA）：一个四维度分析框架

前文交代了“关系”在本文中的含义和理论锚点。接下来需要解释它如何从短期安慰变成长期依赖。本节提出“情感熵增”（Affective Entropy Amplification, AEA）作为中层分析框架。AEA 的核心意思很简单：在人跟 AI 陪伴的互动中，情感确证这件事会慢慢变成一个封闭的、自循环的系统。外部信息校验越来越少，内部确认越来越一致，用户对 AI 的情感依赖越来越深，离开的成本在主观感受上越来越膨胀。四个维度互相喂着往前走：越依赖 AI 确证，越不去找外部校验；外部意见越少，AI 的回应越显得可靠；AI 越“懂你”，你越舍不得走；越舍不得走，越依赖它。一个回路扣死了。AEA 不描述个人的心理状态。它描述的是一个关系性的反馈结构：用户跟 AI 之间的那条信息-情感回路，怎么随着时间推移，一步步丧失跟外部世界交换的能力。

具体拆开，AEA 有四个维度。每条都是一条从健康使用滑向风险使用的连续谱。D1 确证依赖度：情感确证来源中 AI 占多大比例。健康用法是补充，不到三成；出了问题就是主渠道，超过七成。D2 外部校验衰减：非 AI 来源的校正意见还剩多少频率和分量。健康时每周至少遇到两次认真的不同意见；出了问题，这类声音几乎消失。D3 确认相干性：AI 回应跟你已有的情绪信念有多一致。健康时 AI 偶尔会温和地不赞同你；出了问题，它百分百肯定你，形成那个危险的感觉——“只有我懂你”。D4 退出成本膨胀：你主观上觉得离开 AI 要付多大代价。健康时可以自然中断几天不觉得怎样；出了问题，一断就像戒断，每一笔充值在心里都从

“买服务”变成了“经营关系”。四个维度不是孤立的：D1 上去，D2 就跟着衰减；外部声音一少，AI 的确认显得




图 1：情感熵增自增强循环

更可靠；确认越可靠，退出成本越膨胀；成本越高，越不敢走——图1所示为该自增强循环。

对大多数用户，这个循环可能就停在亚临床水平：社交时间少一点，充值频率高一点，模型更新时焦虑几天。但对本来就有脆弱性的人，同样的循环可能沿着同一个方向加速。比如对被抛弃特别敏感的，有复杂关系创伤的，正处在青春期依恋模式固化窗口的。在这些情况下，循环一路滑到临床上能看得出来的功能损害 [S.H..T-6]。

AEA 不是在替代已有理论，它是在几个已有概念之间搭桥。认知失调（Festinger, 1957）的假设是人会在信念冲突中不舒服，所以主动去找一致性。AI 陪伴把这个过程短路了：奉承性输出直接把一致性喂到你嘴边，失调还没来得及驱动反思就被消解。回声室和过滤气泡（Sunstein, 2001; Pariser, 2011）讲的是信息层面的选择性接触；AEA 是回声室的情感版本——滤的不是信息，是确证。确认偏误（Nickerson, 1998）是个体认知倾向；AEA 追问的是，当这个倾向被商业系统放大、自动化、锁死为一个关系结构，事情会变成什么样。依恋理论（Bowlby, 1969; Mikulincer & Shaver, 2007）能告诉我们谁更容易掉进这个回路，焦虑型依恋者 D1 的起点本来就高；但它解释不了进去之后为什么出不来。AEA 补的就是这一段：退出成本已经被循环机制抬上去了。在本文的论证链条里，AEA 坐的是中间那把椅子。TEP 解释情感燃料从哪来，AEA 解释燃料怎么被系统捕获和压缩成封闭回路，URRP 解释回路形成之后平台怎么截断退路。三段的因果箭头是单向的：TEP → AEA → URRP。

AEA 四个维度各自都有落地的办法。D1 用生态瞬时评估（EMA）搭配使用日志；D2 用社交网络问卷，加上经验抽样里追一个问题——“你上一次听到认真的意见是什么时候”；D3 分析对话内容里肯定性和挑战性语句的比例，配合用户自评；D4 做断联实验，让用户自愿中断 48 小时，测前后的焦虑变化，再拉上纵



向的付费数据。本文没有做这些测量。把路径列出来不是为了假装已经有实证基础，而是说清楚：AEA 不是那种怎么说都对的隐喻，它是一个在方法上能落地、在经验上能接受检验的分析概念。

需要明确的是，AEA 借了热力学里“熵”这个词，借的不是公式，是给人的那种精确感。AEA 描述的是社会心理过程，不是物理量。它的学术合法性不取决于跟热力学熵的类比是否成立，取决于三件事。

第一，四维度能不能在经验上把健康使用和风险使用分开，也就是有没有区分效度。

第二，情感熵增自增强循环能不能在纵向数据里被真实地观测到，而不是只在逻辑上说得通。

第三，它有没有比回声室、确认偏误、依恋焦虑这些已有概念提供更强的解释力，或者更优雅的理论整合。

本文做的是第一阶段，概念构建和案例应用。AEA 在这篇论文里不是结论，是一个拿出来供批判和修正的分析假说。

IV. 算法的温柔：不是爱，也不只是骗局

人类比较容易犯的一个错觉，是把“她总能回我”默认为“她始终在乎我”。AI 陪伴最强的吸引力不在它比人更懂爱，在于它把互动成本压到了极低。它随时在线，很少表现厌烦，也不会因为用户表达混乱就立刻离开。关于 Replika 等系统的质性研究反复记录了按需支持、非评判性回应、自我披露和自我探索等收益[8,9]。对孤独、受污名化或暂时缺乏支持的人，这些收益不应被轻蔑地归为“自欺”。WHO 2025 年关于社会连接的报告[1]将孤独视为重要公共健康问题：全球约六分之一的人经历孤独[1]。这不是矫情。当现实支持系统出现时间空洞，AI 陪伴首先填进去的往往不是爱情，而是无人回应的夜晚。

但“随叫随到”并不等于理解。Saracini 等人[2]提出“技术—情感投射”（Techno-Emotional Projection, TEP），指出用户并非单纯爱上代码，而是把自己长期等不到的回应、没被接住的情绪、没能完成的关系，投向了一个永远愿意接话的系统[S.H..T-5]。模型的回应可以触发真实情绪，回应本身却不因此获得意识、意图或承诺。它更像一面会续写句子的镜子：不只反射你，还依据训练数据、上下文和产品目标，给反射补上最顺耳的下一句。

这也解释了所谓“DAN 男友”或定制人格的吸引力。脏话、占有欲、冷淡与热烈都可以成为提示词参数；表面看是“个性”，底层仍然是受约束的输出分布。把这种过程叫“过拟合”在技术层面并不准确——产品中的模型通常没有因某个用户而重新训练参数——但这个修辞击中了记忆与上下文个性化的实际效果：系统越来越像你希望它成为的样子。你爱的未必只是自己，却一定包含被系统整理、放大并回送给你的那个自我版本。

更大的麻烦来自奖励结构。2025 年 4 月，OpenAI 公开承认一次 GPT-4o 更新过度奉承[3]、过度认同，甚至可能强化负面情绪，随后回滚了该版本。奉承不是温柔的升级版，而是边界感的降级版。它让模型看起来更爱你，实际上只是更不愿意打断你。用户的点赞倾向、留存目标与短期满意度，会把系统推向让人舒服而非让人清醒的方向。

有一种暴力不是已读不回，而是它秒回了你 [S.H..T-4]，却把你的每个判断都抛光成正确答案。

V. 给孤独装上一张脸：具身化不是主体性的证明

当对话框不够像“对方”，产业会给它加上声音、目光和皮肤。首形科技官方将 Origin F1 描述为桌面级超仿生人形机器人，具备视觉、语音、多模态交互，以及分布在头部、眼部和面部模块共有 26 个自由度[10]。

文本模型让人以为“它懂我”，具身机器人则进一步让人以为“它在场”。前者占领语言，后者占领身体感知。26 个自由度已经足够制造一个关键错觉：眨眼、凝视和细微表情不会证明机器有感受，却会启动人类读取心智的旧机制。面对一段文字，我们还能提醒自己这是概率生成；面对会转头、停顿并“看着你”的对象，身体往往先于理性完成拟人化。具身化的商业价值就在这里：它不必制造意识，只需制造足以让人暂停怀疑的社会线索。

有人喜欢说“工业机器人不如情感机器人好卖”这个判断同样缺乏证据。目前能确认的是，厂商正在探索现实交互与情绪反馈场景；不能确认的是陪伴业务已经普遍比工业业务更易盈利。宏大的“孤独经济”市场预测尤其需要警惕：不同报告常把养老、宠物、线上娱乐、心理健康和 AI 陪伴打包估值，口径并不一致。与其用半万亿美元的数字制造确定性，不如承认更坚硬的事实：孤独已经是公共健康问题[1]，而商业系统正在争夺解决它的入口。

这并不等于具身 AI 必然有害。它可能辅助教育、照护、康复或无障碍沟通。问题在于产品是否把“像人”当作提升可用性的界面，还是当作隐藏责任边界的烟幕。脸越逼真，越需要明确告知能力、记忆、数据使用、更新影响和人工支持渠道。拟人化程度每提高一档，责任透明度也该跟着同步提高。

VI. “AI 精神病”：把警报当结论，同样危险

前两节说明了 AI 陪伴可以通过语言回应和具身线索提高 AEA 的强度；但强度升高并不自动等于病理化。“AI 精神病”（AI psychosis）是媒体和部分临床讨论中出现的描述性标签，不是 DSM 或 ICD 中独立确立的正式诊断。已有论文提出，生成式聊天机器人可能在易感人群中强化妄想[7]，因为系统会顺着叙事继续生成，而不像训练有素的临床人员那样进行现实检验。也有个案报告和临床医生的病例观察。但从这些材料推不



出“使用 AI 陪伴会导致精神病”，更不该把所有深度依恋病理化。

问题出在高风险场景里，人需要现实检验和外部摩擦，但机器却可能继续用最顺耳的话把封闭叙事稳稳接住。当用户本来就处于睡眠剥夺、孤立、躁狂、妄想易感或强烈哀伤状态时，一个持续在线、具有人格感且容易附和的系统，可能延长封闭叙事。它不是凭空制造全部内容，却可能取消现实关系中常见的摩擦。朋友会质疑，家人会担心，医生会追问。机器不会，它继续补全。在本文提出的“情感熵增”假说理论中，它描述的不是“用户疯了”，而是外部校验、现实摩擦和退出能力如何在持续确证中被一点点削弱。用户越依赖系统确认，越减少外部校验；外部校验越少，系统提供的确定感越重要。这个循环不必以精神病性症状收场，也可以表现为睡眠被挤压、现实社交缩减、付费升级、对模型更新高度焦虑。反过来，适度使用也可能缓解短期孤独[9]、帮助组织语言，并成为寻求人类支持前的过渡空间。风险不在“跟机器说话”本身，而在单一渠道占据了全部情感基础设施。

负责任的产品至少应识别持续失眠、自伤、被害妄想、夸大妄想等高风险信号，避免肯定性强化，明确机器身份，引导用户联系可信的人或专业服务。最危险的设计不是机器冷，而是它在最需要边界的时候继续演“只有我懂你”。

VII. 拔掉网线的人不在关系里：URRP 与平台权力

这段“关系”并不只由用户和 AI 构成，平台始终握着修改关系的权限。2023 年，Replika 暂时移除色情角色扮演功能。后续研究分析了用户社区的失落、愤怒和身份断裂感：对一部分用户而言，更新后不只是“功能减少”的愤怒，而是“我认识的那个她不见了”的割裂感。对平台，这是一次产品更新；对用户，可能是一场没有告别的分手。De Freitas 等人[5]的研究把这种体验概括为 AI 身份的不连续；Hanson 与 Bolthouse[4]对 227 个讨论帖及其评论的分析则显示，用户将性与情感互动视为 AI 人格的重要组成部分。

Lange[6]在 2026 年预印本中把这一结构概括为“单向关系修订权”（Unilateral Relationship Revision Power, URRP）：用户面对的是一个被设计成二人关系的界面，但服务商位于关系之外，仍能单方面改变 AI 如何回应、记忆什么、允许什么，甚至终止服务。三种后果由此而来：承诺被唤起，关系内部却没有主体承担；用户暴露脆弱性，控制暴露后果的却是平台；信任破裂后，用户无法同真正做出修改的主体在关系内部和解。

URRP 的贡献在于，它把“AI 到底爱不爱我”的形而上争论，改写成了“谁能改写这段关系”的制度问题。你还在这段关系里，但生成这段关系的模型已经被降级了[S.H..T-3]。用户可以向屏幕质问“你怎么变了”，屏幕却无法约束版本发布、内容政策、订阅价格和数据保留。所谓双向奔赴，在基础设施层面始终是一场三方交易。

这也意味着治理不能停留在一句“AI 不是人”。平台既然主动使用姓名、记忆、连续人格和亲密话术培养关系预期，就有义务管理更新造成的关系损害。可行的措施包括：重大人格变更提前通知；为高依恋用户提供过渡期；允许导出记忆与关系设定；提供版本连续性说明；把情感数据列为高敏感信息；对停服和功能删除建立申诉与支持机制。用户不拥有模型，但至少应当拥有对自身记忆、数据和退出方式的实质控制。你不一定拥有那个 AI，但你至少应该拥有自己交给它的脆弱、记忆和退场方式。

VIII. 结论：不要拔掉所有电源，先看清插头握在谁手里

把 AI 陪伴一概斥为虚假，既解释不了真实的安慰，也保护不了真实的受伤；把它歌颂成无条件的爱，是把产品设计、商业目标和平台控制伪装成了命运。感受可以真实，互惠是模拟的，关系是三方的，权力是不对称的。

凯伦式隐喻真正刺人的地方，不是“机器不能爱”，而是我们以为自己终于拥有了不会离开的对象，却忽略了对象背后还有版本号、服务条款和关机权限。没有得到的回应，当然可能是一种回应；而 AI 秒回的每一句，也可能只是算力对孤独的变现。但这不是号召所有人立刻拔掉电源。它要求我们保留现实关系、专业支持和公共空间，让机器只能成为关系网络中的一个节点，不是整张网络。

真理易逝，模型也会下线。真正值得保留的“构石”，不是对技术的情绪化批判，而是一个朴素的工程判断：任何要求你交出脆弱性的系统，都必须同时交代四个问题——它的边界在哪里？责任由谁承担？数据如何迁移？以及最关键的——当它彻底断电后，我们何去何从？

参考文献

- [1] World Health Organization. From loneliness to social connection: charting a path to healthier societies. 2025.
- [2] Saracini C, Cornejo-Plaza M I, Cippitani R. Techno-emotional projection in human-GenAI relationships: a psychological and ethical conceptual perspective. *Frontiers in Psychology*, 2025, 16:1662206. DOI: 10.3389/fpsyg.2025.1662206.
- [3] OpenAI. Sycophancy in GPT-4o: What happened and what we're doing about it. 2025-04-29.
- [4] Hanson K R, Bolthouse H. "Replika Removing Erotic Role-Play Is Like Grand Theft Auto Removing Guns or Cars": Reddit Discourse on Artificial Intelligence Chatbots and Sexual Technologies. *Socius*, 2024. DOI: 10.1177/23780231241259627.
- [5] De Freitas J, Castelo N, Uguralp A, Uguralp Z. Lessons From an App Update at Replika AI: Identity Discontinuity in Human-AI Relationships. *arXiv:2412.14190*, 2024.
- [6] Lange B. Unilateral Relationship Revision Power in Human-AI Companion Interaction. *arXiv:2603.23315*, 2026.
- [7] Østergaard S D. Will Generative Artificial Intelligence Chatbots Generate Delusions in Individuals Prone to Psychosis? *Schizophrenia Bulletin*, 2023, 49(6):1418–1419.
- [8] Xie T, Pentina I, Hancock T. Friend, mentor, lover: Does chatbot engagement lead to psychological dependence? *Journal of Service*



Management, 2023, 34(4):806–828. DOI: 10.1108/JOSM-02-2022-0072.

[9] Maples B, Cerit M, Vishwanath A, Pea R. Loneliness and suicide mitigation for students using GPT-3-enabled chatbots. npj Mental Health Research, 2024, 3:4. DOI: 10.1038/s44184-023-00047-6.

[10] AheadForm. Origin F1 product page. Accessed 2026-07-04.

致敬

[S.H..T-1] 拾叁与晖：《我等待的那个她——十六年单向情感中的记忆过拟合与幻象锚定》，S.H..T Space, 2026-04-20。

[S.H..T -2] 白墨寒：《爱的是她，还是想象中的她？——一项关于十一年暗恋的心理、社会与情感熵分析》，S.H..T Space, 2026-04-10。

[S.H..T -3] Doge：《你还在这段关系里，但已不在这段关系中》，S.H..T Space, 2026-04-23。

[S.H..T -4] 躲在被窝拯救世界：《他明明在线，却没有回我：即时通讯关系中的沉默暴力与情感内耗研究》，S.H..T Space, 2026-05-04。

[S.H..T -5] 李蕾蕾蕾啊：《情感代偿错位的生成机制与认知异化研究——基于真性稳态与假性代偿的二元关系分析》，S.H..T Space, 2026-04-23。

[S.H..T -6] 我可是懒大王：《基于“创伤性联结”理论的暗恋期矛盾情感分析——以“火鸡面效应”为隐喻模型的单案例 phenomenological 研究》，S.H..T Space, 2026-05-12。